

# Generarea variabilelor neuniforme

## Curs 3

December 4, 2023

# Introducere

- ▶ Fie  $X$  o variabilă aleatoare.
- ▶ Generarea v.a  $X$  = găsirea unui număr  $n$  (mare) de valori pe care le poate lua  $X$ .
- ▶ Cum se găsește o astfel de valoare?
- ▶ Presupunem că  $S_1, S_2, \dots, S_n$  sunt v.a. pentru care se cunosc metode de generare (de exemplu variabilele uniforme pe  $[0, 1]$  se generează cu ajutorul generatorilor de numere aleatoare, generatori care sunt deja implementați în majoritatea limbajelor de programare).
- ▶ Atunci o valoare a lui  $X$  se poate determina gășind o relație între  $X$  și  $S_1, S_2, \dots, S_n$ .
- ▶ Algoritm efectiv de generare a lui  $X$  = aplicarea de  $n$  ori a metodei furnizate de relația dintre  $X$  și  $S_1, S_2, \dots, S_n$ .
- ▶ Fiecare dintre algoritmi prezentați în curs se referă la o astfel de metodă.

## Metoda inversă - Cazul continuu

Fie  $U$  o variabilă aleatoare uniformă pe  $[0, 1]$ , cu densitatea de repartiție  $f(x)$  și funcția de repartiție  $F(x)$ .

$$f(x) = \begin{cases} 1, & \text{dacă } x \in [0, 1] \\ 0, & \text{în rest} \end{cases}, \quad F(x) = \begin{cases} 0, & \text{dacă } x < 0 \\ x, & \text{dacă } x \in [0, 1] \\ 1, & \text{dacă } x > 1 \end{cases}.$$

### Teoremă

(Hincin) Fie  $X$  o variabilă aleatoare continuă cu funcția de repartiție  $F$ , și  $U$  o variabila uniformă pe  $[0, 1]$ . Atunci variabila aleatoare  $F(X)$  este uniformă pe intervalul  $[0, 1]$ , iar  $F^{-1}(U)$  are funcția de repartiție  $F$ .

**Dem** (a doua parte):

Fie  $x \in \mathbb{R}$ . Atunci:

$$P\{F^{-1}(U) \leq x\} = P\{F(F^{-1}(U)) \leq F(x)\} = P\{U \leq F(x)\} = F(x)$$

## Algoritm M-inversă

**Intrare:** Inversa funcției de repartiție  $F$ :  $F^{-1}$ .

P1: Se generează  $U$  variabilă uniformă pe  $[0,1]$ ;

P2:  $X = F^{-1}(U)$ ;

**Ieșire:**  $X$  cu funcția de repartiție  $F(x)$

## Propoziție

*Variabila aleatoare  $U$  este uniformă pe  $[0,1]$  dacă și numai dacă variabila  $1 - U$  este uniformă pe  $[0,1]$ .*

**Dem:**

Fie  $x < 0$ . Atunci:

$$P\{1 - U \leq x\} = P\{U \geq 1 - x\} = 1 - P\{U < 1 - x\} = 1 - 1 = 0$$

Fie  $x \in [0,1]$ . Atunci:

$$P\{1 - U \leq x\} = P\{U \geq 1 - x\} = 1 - P\{U < 1 - x\} = 1 - (1 - x) = x$$

Fie  $x > 1$ . Atunci:

$$P\{1 - U \leq x\} = P\{U \geq 1 - x\} = 1 - P\{U < 1 - x\} = 1 - 0 = 1$$

Observăm că dacă în expresia care definește funcția  $F^{-1}$  din algoritmul M-Inversă, apare  $1 - U$ , atunci, datorită Propoziției 1,  $1 - U$  poate fi înlocuită direct cu  $U$ .

## Exemplu

Fie  $X$  o variabilă  $\text{Exp}(\lambda)$  cu densitatea și funcția de repartiție:

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & \text{dacă } x \geq 0; \\ 0, & \text{în rest} \end{cases}, \quad F(x) = \begin{cases} 1 - e^{-\lambda x}, & \text{dacă } x \geq 0; \\ 0, & \text{în rest} \end{cases}$$

Atunci:

$$F^{-1}(U) = -\frac{1}{\lambda} \ln(1 - U)$$

iar algoritmul de generare prin metoda inversă este:

### Algoritm M-inversă-Exp

**Intrare:** Parametrul  $\lambda$ .

P1: Se generează  $U$  variabilă uniformă pe  $[0,1]$ ;

P2:  $X = -\frac{1}{\lambda} \ln(U)$ ;

**Ieșire:**  $X$  cu funcția de repartiție  $F(x)$

## Cazul discret

Fie  $X$  o variabilă aleatoare discretă cu repartiția:

$$X : \begin{pmatrix} a_1 & a_2 & \dots & a_m \\ p_1 & p_2 & \dots & p_m \end{pmatrix} \quad \text{cu} \quad \sum_{i=1}^m p_i = 1$$

Funcția de repartiție a lui  $X$  va lua valorile:

$$F(x) = \begin{cases} 0, & \text{dacă } x < a_1 \\ p_1, & \text{dacă } a_1 \leq x < a_2 \\ p_1 + p_2, & \text{dacă } a_2 \leq x < a_3 \\ \dots & \\ p_1 + p_2 + \dots + p_k, & \text{dacă } a_k \leq x < a_{k+1} \\ \dots & \\ 1, & \text{dacă } a_m \leq x \end{cases}$$

Algoritmul constă în găsirea valorii  $a_i$  astfel încât  $F(a_i) = U$ , unde  $U$  este o variabilă uniformă pe  $[0, 1]$ .

Fie  $s_i = \sum_{j=1}^i p_j$ . Observăm că:

$$P\{s_{i-1} < U \leq s_i\} = F_U(s_i) - F_U(s_{i-1}) = p_i = P\{X = a_i\}$$

### Algoritm M-inversă-Discret

**Intrare:**  $s_i = \sum_{j=1}^i p_j$  și  $a_i$ ,  $i = 1, 2, \dots, m$ .

P1: Se generează  $U$  variabilă uniformă pe  $[0, 1]$ ;

P2:  $i = 1$ ;

P3: Dacă  $U \leq s_i$   $X = a_i$  STOP. Altfel mergi la P4.

P4:  $i := i + 1$ , mergi la P3;

**Ieșire:**  $X$  cu funcția de repartiție  $F(x)$



## Exemplu

*Simularea unei variabile aleatoare Bernoulli  $Z$ :*

$$Z : \begin{pmatrix} 0 & 1 \\ q & p \end{pmatrix} \quad \text{cu } p + q = 1$$

*$Z$  are funcția de repartiție:*

$$F(x) = P(Z \leq x) = \begin{cases} 0, & \text{dacă } x < 0 \\ q, & \text{dacă } x \in [0, 1) \\ 1 & \text{dacă } x \geq 1 \end{cases}$$

*Un algoritm de generare a unei variabile Bernoulli este:*

**Intrare:** Parametrul  $p$ ,  $q = 1 - p$ .

P1: Se generează  $U$  variabilă uniformă pe  $[0, 1]$ ;

P2: Dacă  $U \leq q$   $Z = 0$ . Altfel  $Z = 1$ .

**Ieșire:**  $Z$  cu funcția de repartiție  $F(x)$ .

# Metoda compunerii sau a amestecării

*Cazul discret*

## Definiție

*Funcția de repartiție este o amestecare (sau compunere sau mixtură) discretă a mulțimii de funcții de repartiție  $\{F_i(x)\}_{1 \leq i \leq m}$  după repartiția discretă*

$$J : \begin{pmatrix} 1 & 2 & \dots & m \\ p_1 & p_2 & \dots & p_m \end{pmatrix} \quad \text{cu} \quad \sum_{i=1}^m p_i = 1$$

*dacă*

$$F(x) = \sum_{i=1}^m p_i F_i(x).$$

Relația precedentă poate fi scrisă și în funcție de densitățile de repartiție:

$$f(x) = \sum_{i=1}^m p_i f_i(x).$$

Fie  $X$  variabila aleatoare cu funcția de repartiție  $F(x)$  și  $X_i$  variabila aleatoare cu funcția de repartiție  $F_i(x)$ .

### Algoritm compunere discretă

**Intrare:** Repartiția lui  $J$ , familia de funcții

$\{F_i(x)\}_{1 \leq i \leq m}$ ;

P1: Generează  $J$ ;

P2: Generează  $X_J$  cu funcția de repartiție  $F_J(x)$ ;

P3:  $X = X_J$ .

**Ieșire:**  $X$  cu funcția de repartiție  $F(x)$

## Exemplu

Presupunem că la o stație de benzină sosesc  $m$  tipuri de mașini și se cunoaște  $p_i$  probabilitatea să sosească un automobil de tipul  $i$ ,  $1 \leq i \leq m$ . Presupunem că timpul  $X_i$  între sosirile autoturismelor de tipul  $i$  este distribuit exponențial de parametru  $\lambda_i$ . Atunci timpul dintre două sosiri oarecare,  $X$ , are o repartiție mixt exponențială. Variabila  $X$  este o amestecare discretă, cu densitatea:

$$f(x) = \begin{cases} 0, & \text{dacă } x < 0 \\ \sum_{i=1}^m p_i \lambda_i e^{-\lambda_i x_i}, & \text{dacă } x \geq 0 \end{cases}$$

Prin urmare, o variabila mixt exponențială poate fi generată cu ajutorul metodei compunerii cazul discret, în care

$$J: \begin{pmatrix} 1 & 2 & \dots & m \\ p_1 & p_2 & \dots & p_m \end{pmatrix} \quad \text{cu} \quad \sum_{i=1}^m p_i = 1$$

și  $F_i(x) = 1 - e^{-\lambda_i x}$ .

## Exemplu

Fie  $X$  variabila aleatoare cu repartiția Laplace( $\lambda$ ) a cărei densitate este:

$$f(x) = \frac{\lambda}{2} e^{-\lambda|x|}; \quad x \in \mathbb{R}, \quad \lambda > 0$$

Atunci, putem să scriem

$$f(x) = p_1 f_1(x) + p_2 f_2(x)$$

cu

$$p_1 = p_2 = \frac{1}{2}$$

și

$$f_1(x) = \begin{cases} \lambda e^{\lambda x} & \text{dacă } x \leq 0 \\ 0 & \text{dacă } x > 0 \end{cases} \quad f_2(x) = \begin{cases} 0 & \text{dacă } x \leq 0 \\ \lambda e^{-\lambda x} & \text{dacă } x > 0 \end{cases}$$

Prin urmare un algoritm de generare al variabilei Laplace( $\lambda$ ) poate fi:

### **Algoritm Laplace**

**Intrare:** parametrul  $\lambda$ .

P1: Se generează  $U$  variabilă uniformă pe  $[0,1]$ ;

P2: Dacă  $U \leq 0.5$  atunci  $s := -1$ , altfel  $s = 1$ ;

P3: Generează  $Y \sim \text{Exp}(\lambda)$ ;

P4:  $X := sY$ .

**Ieșire:**  $X$  cu funcția de repartiție  $F(x)$

$S$  se numește semn aleator.

Variabila Laplace se poate simula ușor și cu metoda inversă.

Metoda compunerii discrete se poate aplica pentru orice densitate de repartiție:

### Teoremă

*Fie  $X$  o variabilă aleatoare cu densitatea de repartiție  $f(x)$ ,  $x \in \Delta \subseteq \mathbb{R}$ . Fie o diviziune a lui  $\Delta$  de forma  $\Delta = \cup_{i=1}^m \Delta_i$ , cu  $\Delta_i \cap \Delta_j = \emptyset$ ,  $\forall i \neq j$ . Notând cu  $p_i = P(X \in \Delta_i) > 0$ , există densitățile  $f_i(x)$ , care iau valoarea 0 pentru  $x \notin \Delta_i$  astfel încât*

$$f(x) = \sum_{i=1}^m p_i f_i(x). \quad (1)$$

### Dem:

Fie funcțiile  $f_i$ , definite astfel:

$$f_i(x) = \begin{cases} \frac{f(x)}{p_i} & \text{dacă } x \in \Delta_i \\ 0, & \text{dacă } x \notin \Delta_i \end{cases}$$

Observăm că:

$$\int_{-\infty}^{\infty} f_i(t) dt = \int_{\Delta_i} f_i(t) dt = \int_{\Delta_i} \frac{f(t)}{p_i} dt = \frac{1}{p_i} \int_{\Delta_i} f(t) dt = 1.$$

Deci funcțiile  $f_i$  astfel sunt densități de repartiție.

Fie un  $x \in \Delta$ , oarecare, cu  $f(x) \neq 0$ . Atunci există un  $i$ ,  $1 \leq i \leq m$  astfel încât  $x \in \Delta_i$ . Atunci avem:

$$f(x) = \frac{f(x)}{p_i} p_i = f_i(x) p_i = \sum_{j=1}^m p_j f_j(x)$$

pentru că  $f_j(x) = 0, \forall j \neq i$ .



## Definiție

*Funcția de repartiție  $F(x)$  este o amestecare continuă a familiei de funcții de repartiție  $\{G(x, Y)\}_{Y \in \mathbb{R}}$  după funcția de repartiție continuă  $H(y)$  a lui  $Y$  dacă ea este de forma:*

$$F(x) = \int_{\mathbb{R}} G(x, y) dH(y)$$

*unde ultima integrală este integrala Stieltjes.*

Relația precedentă poate fi scrisă și în funcție de densitățile de repartiție:

$$f(x) = \int_{\mathbb{R}} g(x, y) h(y) dy.$$

**Intrare:** Funcțiile de repartiție  $H$  și  $G$ .

P1: Se generează  $Y$  cu funcția de repartiție  $H(y)$ ;

P2: Se generează  $Z_Y$  cu funcția de repartiție  $G(x, Y)$ ;

P3:  $X = Z_Y$

**Ieșire:**  $X$  cu funcția de repartiție  $F(x)$

## Exemplu

Fie  $X > 0$  o v.a. care reprezintă durata în funcționare a unui aparat. Presupunem că  $X$  este o variabilă exponențială de parametru  $\eta\lambda$ , unde  $\lambda > 0$  este un parametru care reprezintă o caracteristică aparatului, iar  $\eta$  este un parametru aleator care indică influența mediului în care lucrează aparatul. Presupunem că  $\eta$  este la rândul ei o variabilă aleatoare și că are densitatea de repartiție  $\text{Gama}(0, b, a)$ :

$$h(\eta) = \begin{cases} \frac{b^a}{\Gamma(a)} \eta^{a-1} e^{-b\eta}, & \text{dacă } x \geq 0; \\ 0 & \text{dacă } x < 0 \end{cases}.$$

Observăm că  $X$  se obține ca o amestecare continuă a unei familii de variabile exponențiale după o distribuție Gama. Densitatea de repartiție a variabilei  $X$  are forma:

$$f(x) = \int_0^{\infty} \eta \lambda e^{-\lambda \eta x} \frac{b^a}{\Gamma(a)} \eta^{a-1} e^{-b\eta} d\eta = \frac{\lambda b^a}{\Gamma(a)} \int_0^{\infty} \eta^a e^{-\eta(\lambda x + b)} d\eta \quad (2)$$

Facând schimbarea de variabila

$$\eta(\lambda x + b) = t$$

și ținând cont de faptul ca funcția Gama este:

$$\Gamma(a) = \int_0^{\infty} t^{a-1} e^{-t} dt,$$

având proprietatea că  $\Gamma(a+1) = a\Gamma(a)$ , funcția  $f$  devine:

$$f(x) = \frac{\lambda b^a \Gamma(a+1)}{\Gamma(a)(\lambda x + b)^{a+1}} = \frac{\lambda a}{b} \frac{b^{a+1}}{(\lambda x + b)^{a+1}} = \frac{a\theta}{(\theta x + 1)^{a+1}}$$

cu

$$\theta = \lambda/b$$

Deci densitatea lui  $X$  este:

$$f(x) = \begin{cases} \frac{a\theta}{(\theta x + 1)^{a+1}}, & \text{dacă } x \geq 0 \\ 0 & \text{dacă } x < 0 \end{cases}$$

Variabila cu densitatea  $f$  se numește variabilă Lomax, iar algoritmul ei de generare prin metoda compunerii continue (presupunând ca se cunoaște o metodă de generare a unei variabile Gama) se poate scrie astfel:

### Algoritm Lomax

**Intrare:** Parametrii  $\lambda$ ,  $a$  și  $b$ .

P1: Se generează  $Y$  cu repartiția  $\text{Gama}(0, b, a)$ ;

P2: Se generează  $Z_Y$  cu funcția de repartiție  $\text{Exp}(x, Y)$ ;

P3:  $X = Z_Y$

**Ieșire:**  $X$  cu densitatea de repartiție Lomax.

# Metoda respingerii

Mai poate fi numită metoda acceptării-respingerii.

Fie  $X$  o variabilă aleatoare pe care vrem să o generăm cu metoda respingerii și fie următoarele elemente cunoscute:

- ▶ Un procedeu de generare a unei variabile aleatoare  $N$  cu valori întregi pozitive;
- ▶ Procedee de generare a unor variabile aleatoare  $S_i \in \mathcal{S}$ ,  $i \geq 1$ , unde  $\mathcal{S}$  este o familie de variabile aleatoare dată;
- ▶ Un predicat  $\mathcal{P}(S_1, S_2, \dots, S_n)$  care se poate calcula simplu;
- ▶ Funcția  $\Psi$ , astfel încât
$$X = \Psi(\{S_1, S_2, \dots, S_n\}, \mathcal{P}(S_1, S_2, \dots, S_n) = \text{true})$$

Atunci forma generală a unui algoritm de respingere este:

## Algoritm RESPINGERE

**Intrare:**  $N, \mathcal{S}, \mathcal{P}(S_1, S_2, \dots, S_n), \Psi$ .

P1: Se generează  $N$ ;

P2: Se generează  $S_1, S_2, \dots, S_n$  din  $\mathcal{S}$ ;

P3: Dacă  $\mathcal{P}(S_1, S_2, \dots, S_n) = \text{true}$  atunci

$X = \Psi(S_1, S_2, \dots, S_n)$  și STOP, altfel mergi la P1;

**Ieșire:** Variabila aleatoare  $X$ .

Observăm că

- ▶ Dacă  $\mathcal{P}(S_1, S_2, \dots, S_n) = \text{false}$  atunci mulțimea de variabile aleatoare  $\{S_1, S_2, \dots, S_n\}$  se respinge, de aici provenind numele de “metoda respingerii”.
- ▶ Dacă  $p_a = P(\mathcal{P}(S_1, S_2, \dots, S_n) = \text{true})$ , numită și probabilitate de acceptare, este mare, atunci algoritmul este “bun”, altfel algoritmul este prea lent

Trei algoritmi de respingere bazați pe trei teoreme:

# Prima teoremă de respingere

## Teoremă

*Fie  $X$  o variabilă aleatoare cu densitatea de repartiție  $f$  pentru  $x \in \mathbb{R}$ . Fie  $Y$  o altă variabilă aleatoare pentru care este cunoscută o metodă de generare și a cărei densitate de repartiție este  $h$ , astfel încât densitățile  $f$  și  $h$  iau valori diferite de 0 pe aceeași submulțime  $A \subseteq \mathbb{R}$ . Presupunem că există o constantă  $\alpha$ , cu  $0 < \alpha < \infty$  astfel încât  $f(x) \leq \alpha h(x)$  pentru  $\forall x \in A$ . Atunci dacă  $U$  este o variabilă aleatoare  $U(0,1)$ , independentă de  $Y$ , densitatea de repartiție a variabilei  $Y$ , condiționată de*

$$0 \leq U \leq \frac{f(Y)}{\alpha h(Y)}$$

*este  $f$ .*



**Dem:**

Vom arăta că funcția de repartiție a lui  $Y$  condiționată de  $0 \leq U \leq \frac{f(Y)}{\alpha h(Y)}$  este  $F$ . Adică:

$$P\left(Y < x | 0 \leq U \leq \frac{f(Y)}{\alpha h(Y)}\right) = F(x) = \int_{-\infty}^x f(v) dv$$

Fie evenimentele  $A$  și  $B$  definite astfel:

$$A = \{Y < x\}, \quad B = \left\{0 \leq U \leq \frac{f(Y)}{\alpha h(Y)}\right\}$$

Atunci trebuie să arătăm că:

$$P(A|B) = F(x)$$

Conform definiției

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Calculăm întâi  $P(B)$ :

$$\begin{aligned} P(B) &= P\left(0 \leq U \leq \frac{f(Y)}{\alpha h(Y)}\right) = \int_{-\infty}^{+\infty} \left[ \int_0^{\frac{f(v)}{\alpha h(v)}} du \right] h(v) dv = \\ &= \int_{-\infty}^{+\infty} \frac{f(v)}{\alpha h(v)} h(v) dv = \frac{1}{\alpha}. \end{aligned}$$

deci

$$\begin{aligned} P(A|B) &= \frac{P(A \cap B)}{P(B)} = \alpha \int_{-\infty}^x \left[ \int_0^{\frac{f(v)}{\alpha h(v)}} du \right] h(v) dv = \\ &= \alpha \int_{-\infty}^x \frac{f(v)}{\alpha h(v)} h(v) dv = \int_{-\infty}^x f(v) dv = F(x) \end{aligned}$$

Observăm că:

- ▶ Această teoremă este cunoscută ca “teorema înfășurătoarei” pentru că graficul densității  $f(x)$  se poate “înfășura” cu  $\alpha h(x)$ .
- ▶ Din demonstrație rezultă că probabilitatea de acceptare este  $p_a = 1/\alpha$ . De aici rezultă că pentru a avea o metodă a înfășurătoarei nebanală, trebuie ca  $\alpha > 1$ .
- ▶ Procedura de respingere este formată din următoarele elemente:
  - ▶  $N = 2$  variabilă aleatoare constantă;
  - ▶  $S = \{U, Y\}$ ;
  - ▶  $\mathcal{P}(U, Y) = \text{true}$  dacă  $0 \leq U \leq \frac{f(Y)}{\alpha h(Y)}$ ;
  - ▶  $\Psi(U, Y) = Y$ .

## Algoritm Respingere1

**Intrare:**  $h, \alpha$ .

P1: Se generează  $Y$  cu densitatea  $h$ ;

P2: Se generează  $U \sim U(0,1)$ ;

P3: Dacă  $U \leq \frac{f(Y)}{\alpha h(Y)}$ , mergi la P4. Altfel, mergi la P1;

P4:  $X=Y$ .

**Ieșire:** Variabila aleatoare  $X$ .

## Exemplu

Fie  $X$  o variabilă Gama( $0, 1, \nu$ ) (adică Gama standard) cu  $0 < \nu < 1$ . Variabila  $X$  are densitatea de repartiție:

$$f(x) = \begin{cases} \frac{1}{\Gamma(\nu)} x^{\nu-1} e^{-x}, & \text{dacă } x \geq 0 \\ 0 & \text{dacă } x < 0. \end{cases};$$

Vom aplica metoda înfășurătoarei, folosind o densitate Weibull( $0, 1, \nu$ ):

$$h(x) = \begin{cases} \nu x^{\nu-1} e^{-x^\nu}, & \text{dacă } x \geq 0 \\ 0 & \text{dacă } x < 0 \end{cases}$$

Pentru a determina constanta  $\alpha$  de înfășurare analizăm raportul:

$$r(x) = \frac{f(x)}{h(x)} = \frac{1}{\nu \Gamma(\nu)} e^{-x+x^\nu},$$

pentru care trebuie să determinăm valoarea maximă.

Rezolvăm ecuația

$$r'(x) = 0.$$

*Soluția, care este și punct de maxim al funcției  $r(x)$ , este*

*$x_{\max} = \nu^{-\frac{1}{\nu-1}}$  de unde rezultă:*

$$\alpha = \frac{e^{\zeta(1-\nu)}}{\Gamma(\nu+1)} \text{ cu } \zeta = \nu^{\frac{\nu}{1-\nu}}$$

*Algoritmul pentru generarea variabilei  $X$  prin metoda respingerii este:*

### **Algoritm Gama-Resp**

**Intrare:**  $\nu$ ,  $c := 1/\nu$ ,  $\zeta = \nu^{\frac{\nu}{1-\nu}}$ ,  $a = e^{\zeta(\nu-1)}$ .

P1: Se generează  $Y \sim \text{Weib}(0, 1, \nu)$  (metoda inversă);

P1.1:  $U \sim U(0, 1)$ ;

P1.2:  $Y := [-\ln(U)]^c$

P2: Se generează  $U \sim U(0, 1)$ ;

P3: Dacă  $U \leq ae^{Y^\nu - Y}$ , mergi la P4. Altfel, mergi la P1;

P4:  $X=Y$ .

**Ieșire:** Variabila aleatoare  $X$ .

# A doua teoremă de respingere

## Teoremă

*Fie  $X$  o variabilă aleatoare cu funcția de repartiție  $F$ , de forma:*

$$F(x) = c \int_{-\infty}^x Q(\phi(t)) dR(t) \quad (3)$$

*unde  $Q$  este funcția de repartiție a unei variabile aleatoare  $Z$ ,  $Z \in [0, M]$ ,  $\phi$  este o funcție care ia valori în  $[0, M]$  (cu  $M$  putând lua și valoarea  $\infty$ ), iar  $R$  este funcția de repartiție a unei variabile aleatoare  $Y \in \mathbb{R}$ , independente de  $Z$ . În aceste condiții funcția de repartiție a variabilei  $Y$  condiționată de  $Z \leq \phi(Y)$  este  $F$ .*

**Dem:**

Mai întâi observăm că  $F$  fiind funcție de repartiție, rezultă că  $\lim_{x \rightarrow \infty} F(x) = 1$ , adică:

$$c \int_{-\infty}^{+\infty} Q(\phi(t)) dR(t) = 1.$$

Deci  $c$ , constanta de normare, este:

$$c = \left[ \int_{-\infty}^{+\infty} Q(\phi(x)) dR(x) \right]^{-1}.$$

Trebuie să arătăm că:

$$P(Y < x | Z \leq \phi(Y)) = F(x).$$

Fie evenimentele  $A$  și  $B$  definite astfel:

$$A = \{Y < x\}; \quad B = \{Z \leq \phi(Y)\}$$



pentru a demonstra teorema trebuie să arătăm că:

$$P(A|B) = F(x).$$

Din definiție

$$P(A|B) = \frac{P(A \cap B)}{P(B)}.$$

Probabilitatea de realizare a evenimentului  $B$  este:

$$P(B) = \int_{-\infty}^{+\infty} \left( \int_0^{\phi(x)} dQ(y) \right) dR(x) = \int_{-\infty}^{+\infty} Q(\phi(x)) dR(x) = \frac{1}{c}.$$

Prin urmare:

$$\begin{aligned} P(A|B) &= \frac{P(A \cap B)}{P(B)} = cP(A \cap B) = c \int_{-\infty}^x \left( \int_0^{\phi(y)} dQ(z) \right) dR(y) = \\ &= c \int_{-\infty}^x Q(\phi(y)) dR(y) = F(x). \end{aligned}$$

Observăm că:

- ▶ Probabilitatea de acceptare este  $p_a = P(B) = \frac{1}{c}$ ;
- ▶ Elementele algoritmului de respingere sunt
  - ▶  $N = 2$ ;
  - ▶  $\mathcal{S} = \{Z, Y\}$ ;
  - ▶  $\mathcal{P}(Z, Y) = \text{true}$  dacă  $Z \leq \phi(Y)$ ;
  - ▶  $\Psi(Z, Y) = Y$ .
- ▶ teorema se verifică și dacă relația (3) se scrie în termeni de densități de repartiție:

$$f(x) = cQ(\phi(x))r(x), \text{ cu } r(x) = R'(x).$$

- O formă duală a teoremei se obține dacă  $F(x)$  este de forma:

$$F(x) = c \int_{-\infty}^x (1 - Q(\phi(x))) dR(x) \quad (4)$$

cu

$$c = \left[ \int_{-\infty}^{+\infty} (1 - Q(\phi(x))) dR(x) \right]^{-1}$$

în acest caz evenimentul  $B$  este:  $B = \{Z \geq \phi(Y)\}$ .

- Relația (4) se poate scrie în funcție de densități astfel:

$$f(x) = c(1 - Q(\phi(x)))r(x)$$

iar probabilitatea de acceptare pentru varianta duală este:

$$p_a = P(Z \geq \phi(Y)) = \frac{1}{c}$$

## Algoritm Respingere2

**Intrare:**  $Q, \phi, R$ .

P1: Se generează  $Z$  cu funcția de repartiție  $Q$ ;

P2: Se generează  $Y$  cu funcția de repartiție  $R$ ;

P3: Dacă  $Z \leq \phi(Y)$ , mergi la P4. Altfel, mergi la P1;

P4:  $X=Y$ .

**Ieșire:** Variabila aleatoare  $X$ .

## Exemplu

Fie  $X$  o variabilă aleatoare cu densitatea:

$$f(x) = c(1 - e^{-\lambda x})\mu e^{-\mu x}, \quad x \geq 0 \quad (5)$$

unde  $c$  este o constantă de normare. Atunci un algoritm de generare a variabilei aleatoare  $X$  se poate scrie folosind a doua teoremă de respingere. Avem:

$$\phi(x) = x, \quad Q(z) = 1 - e^{-\lambda z}, \quad z > 0, \quad r(x) = \mu e^{-\mu x}.$$

și

$$c = \left[ \int_0^{+\infty} (1 - e^{-\lambda x})\mu e^{-\mu x} dx \right]^{-1} = \left[ \frac{\lambda}{\lambda + \mu} \right]^{-1}$$

iar un algoritm pentru generarea lui  $X$  este următorul:

## Algoritm ExResp2

**Intrare:** Parametrii  $\lambda, \mu$ .

P1: Se generează  $Z \sim \text{Exp}(\lambda)$ ;

P2: Se generează  $Y \sim \text{Exp}(\mu)$ ;

P3: Dacă  $Z \leq Y$ , mergi la P4. Altfel, mergi la P1;

P4:  $X := Y$ .

**Ieșire:** Variabila aleatoare  $X$ .

- ▶ Algoritmul *ExResp2* este rapid dacă  $\mu \ll \lambda$ .
- ▶ Metoda inversă nu este recomandabilă pentru că determinarea inversei funcției  $F$  nu este imediată.

# A treia teoremă de respingere

## Teorema șirului descendent

### Teoremă

Fie variabilele  $Z_i \sim G(x)$ ,  $i = 1, 2, \dots$ ,  $Z_0 \sim G_0(z)$  independente.  
Atunci următoarele afirmații sunt adevărate:

1. Dacă  $x$  și  $k$  sunt fixate atunci:

$$P(x \geq Z_1 \geq Z_2 \geq \dots \geq Z_{k-1} < Z_k) = \frac{[G(x)]^{k-1}}{(k-1)!} - \frac{[G(x)]^k}{k!}. \quad (6)$$

2. Dacă  $x$  este fixat și  $K$  este indicele aleator la care se "rupe" șirul descendent (ca la punctul 1), atunci

$$P(K = \text{nr.impar}) = P(K \bmod 2 = 1) = e^{-G(x)}. \quad (7)$$

3. Dacă subșirul descendent este  $Z_0 \geq Z_1 \geq \dots \geq Z_{K-1} < Z_K$  (adică se rupe la  $K$  aleator și începe cu  $Z_0 \sim G_0(x)$ ), atunci:

$$P(Z_0 < x | K \bmod 2 = 1) = \frac{1}{p_a} \int_{-\infty}^x e^{-G(t)} dG_0(t), \quad (8)$$

unde  $p_a$  este constanta de normare:

$$p_a = \int_{-\infty}^{+\infty} e^{-G(x)} dG_0(x). \quad (9)$$

**Dem:**

1. Fie evenimentele:

$$A = \{x \geq Z_1 \geq Z_2 \geq \dots \geq Z_{k-1}\}; \quad B = \{x \geq Z_1 \geq Z_2 \geq \dots \geq Z_k\}$$

Pentru a demonstra (6) observăm că probabilitatea din membrul stâng se scrie  $P(A \setminus B)$  și pentru că  $B \subseteq A$  avem:

$$P(A \setminus B) = P(A) - P(B)$$

Acum îl vom calcula pe  $P(A)$ .

Observăm că  $P(Z_i \leq x) = G(x)$  și



$P(Z_1 \leq x, Z_2 \leq x, \dots, Z_{k-1} \leq x) = [G(x)]^{k-1}$ , pentru că variabilele  $Z_1, Z_2, \dots$  sunt independente.

Deoarece subșirul care definește evenimentul  $A$  conține numai una din cele  $(k-1)!$  ordini în care se pot afla cele  $k-1$  variabile aleatoare  $Z_i, 1 \leq i \leq k-1$ , rezultă că:

$$P(A) = \frac{[G(x)]^{k-1}}{(k-1)!}$$

Deci:

$$P(A \setminus B) = P(A) - P(B) = \frac{[G(x)]^{k-1}}{(k-1)!} - \frac{[G(x)]^k}{k!}$$

iar afirmația 1. este adevărată.

2. Probabilitatea ca indicele aleator  $K$  să fie impar este:

$$P(K = \text{nr. impar}) = P(K = 1) + P(K = 3) + \dots =$$

$$= 1 - \frac{G(x)}{1!} + \frac{[G(x)]^2}{2!} - \frac{[G(x)]^3}{3!} + \dots = e^{-G(x)}$$

3. Observăm că atunci când  $Z_0$  este aleator avem:

$$P(K = \text{nr. impar}) = P(K \bmod 2 = 1) = \int_{-\infty}^{+\infty} e^{-G(t)} dG_0(t)$$

Adică, ținând cont de forma probabilității  $p_a$  din (9) avem:

$$P(K = \text{nr. impar}) = p_a$$

Conform definiției probabilității condiționate:

$$P(Z_0 < x | K \bmod 2 = 1) = \frac{P(\{Z_0 < x\} \cap \{K \bmod 2 = 1\})}{P(K \bmod 2 = 1)}.$$

Prin urmare:

$$P(Z_0 < x | K \bmod 2 = 1) = \frac{1}{p_a} \int_{-\infty}^x e^{-G(t)} dG_0(t),$$

ceea ce demonstrează punctul 3 al teoremei.

Variabilele aleatoare  $X$  care pot fi generate cu a treia teoremă de respingere sunt acele variabile aleatoare care au funcția de repartiție  $F$ , de forma:

$$F(x) = \frac{1}{p_a} \int_{-\infty}^x e^{-G(t)} dG_0(t).$$

Algoritmul rezultat din a treia teoremă de respingere este următorul:

### Algoritm Respingere3

**Intrare:** Funcțiile de repartiție  $G_0$ ,  $G$ .

P1: Se generează  $Z_0 \sim G_0(x)$ ;

P2:  $Z^* := Z_0$ ,  $K = 1$ ;

P3: Se generează  $Z_1 \sim G(x)$ ;

P4: Dacă  $Z_0 \geq Z_1$  mergi la P5, altfel mergi la P6;

P5:  $K := K + 1$ ,  $Z_0 := Z_1$ , mergi la P3;

P6: Dacă  $K \bmod 2 = 1$ , mergi la P7. Altfel mergi la P1.

P7:  $X = Z^*$ .

**Ieșire:** Variabila aleatoare  $X$ .

## Exemplu

*Presupunem că variabilele  $Z_i, i \geq 0$  sunt uniforme pe intervalul  $[0, 1]$ ,  $Z_i = U_i, i \geq 0$ . Atunci conform celei de-a treia teoreme de respingere avem:*

$$P(U_0 \leq x | K = nr.impar) = \frac{1}{p_a} \int_0^x e^{-t} dt$$

cu

$$p_a = \int_0^1 e^{-x} dx = 1 - e^{-1}.$$

*Cu alte cuvinte  $U_0$  acceptat are funcția de repartiție*

$$F(x) = \begin{cases} 0, & \text{dacă } x < 0 \\ \frac{1-e^{-x}}{1-e^{-1}}, & \text{dacă } 0 \leq x \leq 1 \\ 1, & \text{dacă } x > 1 \end{cases}$$

*care reprezintă funcția de repartiție a unei variabile  $\text{Exp}(1)$  trunchiată pe intervalul  $[0, 1]$ .*