

Generarea variabilelor neuniforme

Curs 5

November 23, 2023

Variabila Exponențială

Fie X o variabilă exponențială de parametru 1 cu densitatea de repartiție

$$f(x) = \begin{cases} e^{-x}, & \text{dacă } x \geq 0 \\ 0, & \text{dacă } x < 0. \end{cases} \quad (1)$$

Fie Y o variabilă exponențială de parametru λ cu densitatea de repartiție

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & \text{dacă } x \geq 0 \\ 0, & \text{dacă } x < 0. \end{cases} \quad (2)$$

Media și dispersia variabilei Y sunt:

$$E[Y] = \frac{1}{\lambda}; \quad \text{Var}[Y] = \frac{1}{\lambda^2} \quad (3)$$

Are loc relația:

$$Y = \frac{X}{\lambda}$$

Pentru a-l genera pe Y este suficient să descriem o metodă de generare pentru X .

Metode de generare pentru $X \sim \text{Exp}(1)$

- Metoda inversă:

$$X = -\log(U)$$

unde U este o variabilă uniformă pe $[0, 1]$.

Are dezavantajul că pentru valori ale lui U apropiate de 0 nu se poate calcula logaritmul.

- Metodă de generare cu a treia teoremă de respingere

Teoremă

În teorema subșirului descendent considerăm $Z_0 = U_0$, $Z_i = U_i$, $i \geq 1$, unde U_0, U_1, \dots sunt uniforme pe $[0, 1]$. Dacă notăm cu N numărul aleator de subșiruri descendente respinse până când se acceptă un subșir, atunci $X = N + Z_0$ este o variabilă $\text{Exp}(1)$, unde Z_0 este variabila acceptată (din ultimul subșir descendent).

Dem:

Din exemplul de la a treia teoremă de respingere, pentru $x \in [0, 1]$ avem:

$$P(Z_0 \leq x | K = nr.impar) = \frac{1}{p_a} \int_0^x e^{-x} dx = F(x) = \frac{1 - e^{-x}}{p_a}$$

cu

$$p_a = 1 - e^{-1}.$$

unde $F(x)$ este funcția de repartiție pentru variabila exponențială trunchiată pe $[0, 1]$.

Deci probabilitatea de a respinge un șir descendent (de forma $Z_0 \geq Z_1 \geq \dots \geq Z_{K-1} < Z_K$) este $p_r = 1 - p_a = e^{-1}$. Prin urmare

$$P(N = n) = e^{-n}(1 - e^{-1}).$$

Trebuie să mai arătăm că:

$$P(N + Z_0 \leq x) = \begin{cases} 0 & \text{dacă } x < 0; \\ 1 - e^{-x}, & \text{dacă } x \geq 0 \end{cases}$$

Fie $x > 0$ oarecare. Notăm cu $k = [x]$ și cu $z = x - k$, $z \in [0, 1)$.
Atunci avem:

$$\begin{aligned} P(N + Z_0 \leq x) &= P(N + Z_0 \leq k + z) = P(N < k) + P(N = k, Z_0 \leq z) = \\ &= \sum_{j=0}^{k-1} (1 - e^{-1}) e^{-j} + (1 - e^{-1}) \frac{e^{-k}}{1 - e^{-1}} \int_0^z e^{-u} du = \\ &= 1 - e^{-k} + e^{-k} (1 - e^{-z}) = 1 - e^{-(k+z)} = 1 - e^{-x}. \end{aligned}$$

Algorithm Resp3-Exp

Intrare:

P1: $N = 0$;

P2: Se generează $U_0, U_1 \sim U(0, 1)$ independente;

P3: $U^* = U_0$, $K = 1$;

P4: Dacă $U_0 \geq U_1$ mergi la P5, altfel mergi la P7;

P5: $K := K + 1$, $U_0 := U_1$;

P6: Se generează $U_1 \sim U(0, 1)$, mergi la P4;

P7: Dacă $K \bmod 2 = 1$ $X = N + U^*$, STOP. Altfel

$N := N + 1$, mergi la pasul 2.

Ieșire: Variabila aleatoare X .

Pe lângă probabilitatea de acceptare $p_a = 1 - e^{-1}$, performanța algoritmului este caracterizată și de numărul N^* al variabilelor uniforme $\{U_i\}_{i \geq 0}$ generate, necesare pentru a obține o valoare de selecție exponențială X . Din evaluarea performanțelor algoritmului celei de-a treia metode de respingere:

$$E[N^*] = \frac{1}{p_a} \left(1 + \int_0^1 e^x dx \right) = \frac{1}{1 - e^{-1}} (1 + e - 1) = \frac{e^2}{e - 1} \approx 4.3$$

Variabila Gama

Fie Y o variabilă aleatoare distribuită $Gama(\alpha, \lambda, \nu)$. Atunci Y are următoarea densitate de repartiție:

$$f(x) = \begin{cases} \frac{\lambda^\nu}{\Gamma(\nu)} (x - \alpha)^{\nu-1} e^{-\lambda(x-\alpha)}, & \text{dacă } x \geq \alpha \\ 0, & \text{altfel} \end{cases}. \quad (4)$$

Cu funcția $\Gamma(\nu)$ definită astfel:

$$\Gamma(\nu) = \int_0^{+\infty} x^{\nu-1} e^{-x} dx.$$

Media și dispersia variabilei Y sunt:

$$E[Y] = \alpha + \frac{\nu}{\lambda}, \quad \text{Var}[Y] = \frac{\nu}{\lambda^2} \quad (5)$$

Fie X o variabilă aleatoare $Gama(0, 1, \nu)$. Atunci X se mai numește variabilă *Gama standard* și are densitatea de repartiție:

$$f(x) = \begin{cases} \frac{1}{\Gamma(\nu)} x^{\nu-1} e^{-x}, & \text{dacă } x \geq 0 \\ 0, & \text{altfel} \end{cases}. \quad (6)$$

Atunci Y se poate scrie

$$Y = \alpha + \frac{X}{\lambda}$$

Prin urmare pentru a genera variabila Y este suficientă găsirea unei metode de generare a variabilei X .

Algoritmii de simulare pentru variabila X depind de intervalul în care se află parametrul ν .

1. Pentru $0 < \nu < 1$

1.1. Generarea variabilei X prin metoda respingerii cu ajutorul unei variabile Weibull (exemplu în **cursul 3**).

1.2. Generarea variabilei X printr-o metodă de compunere-respingere.

Vom scrie densitatea (6) sub forma:

$$f(x) = p_1 f_1(x) + p_2 f_2(x)$$

cu

$$f_1(x) = \begin{cases} \frac{f(x)}{p_1}, & \text{dacă } x \in [0, 1] \\ 0, & \text{altfel} \end{cases}, \quad f_2(x) = \begin{cases} \frac{f(x)}{p_2}, & \text{dacă } x \in (1, +\infty) \\ 0, & \text{altfel} \end{cases}$$

unde

$$p_1 = \frac{\Gamma(1; \nu)}{\Gamma(\nu)}, \quad p_2 = 1 - p_1 = \frac{\Gamma(\nu) - \Gamma(1; \nu)}{\Gamma(\nu)}.$$

Funcția $\Gamma(1; \nu)$ este o funcție gama incompletă:

$$\Gamma(1; \nu) = \int_0^1 x^{\nu-1} e^{-x} dx$$

Presupunem că variabila X_1 are densitatea de repartiție f_1 și că variabila X_2 are densitatea de repartiție f_2 . Atunci are loc următoarea teoremă.

Teoremă

Variabila X_1 se simulează folosind a treia teoremă de respingere (a subșirului descendent) cu $Z_0 = U_0^{1/\nu}$, $Z_i = U_i$, cu $\{U_i\}_{i \geq 0}$ variabile uniforme pe $[0, 1]$. Variabila X_2 se simulează cu a doua teoremă de respingere, forma duală, unde densitatea $f_2(x)$ este de forma

$$f_2(x) = c(1 - Q(x))r(x), \quad x > 0$$

cu

$$c = \frac{1}{e(\Gamma(\nu) - \Gamma(1; \nu))}$$

și

$$r(x) = \begin{cases} e^{-x+1}, & \text{dacă } x \geq 1 \\ 0 & \text{dacă } x < 1 \end{cases}, \quad Q(x) = \begin{cases} 1 - x^{\nu-1}, & \text{dacă } x \geq 1 \\ 0 & \text{dacă } x < 1 \end{cases}$$

Dem:

Fie $x \in [0, 1]$. Atunci aplicând a treia teoremă de respingere avem:

$$G_0(x) = P(U_0^{1/\nu} < x) = P(U_0 < x^\nu) = x^\nu$$

$$\begin{aligned} H(x) &= P(U_0 < x | K = nr.impar) = \frac{1}{p_a} \int_0^x e^{-t} dG_0(t) = \\ &= \frac{1}{p_a} \int_0^x e^{-t} \nu t^{\nu-1} dt \end{aligned}$$

cu

$$p_a = \int_0^1 e^{-t} \nu t^{\nu-1} dt = \nu \Gamma(1; \nu).$$

Dacă derivăm $H(x)$ obținem:

$$H'(x) = h(x) = \frac{e^{-x} x^{\nu-1}}{\Gamma(1; \nu)} = f_1(x), \quad x \in [0, 1]$$

ceea ce demonstrează prima parte a teoremei.

Pentru a demonstra a doua parte îl scriem pe $f_2(x)$ astfel:

$$f_2(x) = \begin{cases} \frac{x^{\nu-1}e^{-x}}{\Gamma(\nu)-\Gamma(1;\nu)}, & \text{dacă } x \geq 1 \\ 0, & \text{dacă } x < 1 \end{cases}$$

adică $f_2(x)$ are forma din enunțul teoremei.

Din această teoremă rezultă următorul algoritm de generare a variabilei X .

Algoritm Gama2

Intrare: $p_1, p_2 = 1 - p_1$;

P1: Se generează $U \sim U(0,1)$;

P2: Dacă $U \leq p_1$ mergi la P3, altfel mergi la P4;

P3: Se generează $X_1 \sim f_1(x)$, $X := X_1$.

P4: Se generează $X_2 \sim f_2(x)$, $X := X_2$.

Ieșire: Variabila aleatoare X .

Variabilele X_1 și X_2 se generează cu următorii algoritmi:

Algoritm Gama2- X_1

Intrare:

P1: Se generează $U \sim U(0, 1)$;

P2: $Z_0 := U^{1/\nu}$;

P3: Se generează $Z_1 \sim U(0, 1)$;

P4: $K := 1$, $Z^* := Z_0$;

P5: Dacă $Z_0 \geq Z_1$ mergi la P6, altfel, mergi la P7;

P6: $Z_0 := Z_1$, se generează $Z_1 \sim U(0, 1)$, $K := K + 1$,
mergi la P5;

P7: Dacă $K \bmod 2 = 1$ $X_1 = Z^*$. Altfel, mergi la P1.

Ieșire: Variabila aleatoare X_1 .

Pentru algoritmul Gama2- X_1 avem:

$$p_a = \nu \Gamma(1; \nu); \quad E(N_1^*) = \frac{1}{p_a} \left(1 + \int_0^1 \nu t^{\nu-1} e^t dt \right)$$

Algoritm Gama2- X_2

Intrare:

P1: Se generează $U \sim U(0, 1)$;

P2: $Z := U^{-\frac{1}{1-\nu}}$;

P3: Se generează $X_0 \sim \text{Exp}(1)$;

P4: $Y := X_0 + 1$;

P5: Dacă $Y > Z$ mergi la P1, altfel mergi la P6;

P6: $X_2 := Y$;

Ieșire: Variabila aleatoare X_2 .

Pentru algoritmul Gama- X_2 avem:

$$p_2 = 1 - p_1; \quad E(N_2^*) = \frac{2}{p_2}$$

și prin urmare numărul mediu de variabile necesare pentru a genera în final un X este:

$$E(N^*) = p_1 E(N_1^*) + p_2 E(N_2^*) = p_1 E(N_1^*) + 2.$$

2. Pentru $\nu > 1$

Doi algoritmi de respingere bazați pe metoda înfășurătoarei (prima teoremă de respingere).

2.1 Primul algoritm de respingere pentru variabila

$X \sim \text{Gama}(0, 1, \nu)$ cu $\nu > 1$.

Considerăm ca înfășurătoare densitatea $h(x) \sim \text{Exp}(\frac{1}{\nu})$, adică:

$$h(x) = \begin{cases} \frac{1}{\nu} e^{-\frac{x}{\nu}} & \text{dacă } x \geq 0 \\ 0 & \text{dacă } x < 0 \end{cases} . \quad (7)$$

Notăm cu $r(x)$ raportul:

$$r(x) = \frac{f(x)}{h(x)} = \frac{\nu x^{\nu-1} e^{-x}}{\Gamma(\nu) e^{-\frac{x}{\nu}}}, \quad \nu > 1$$

Atunci funcția $r(x)$ are un punct de maxim pentru $x = \nu$ și constanta α din teorema înfășurătoarei este:

$$\alpha = r(\nu) = \frac{\nu^\nu e^{1-\nu}}{\Gamma(\nu)}$$

Algoritmul de respingere va avea probabilitatea de acceptare:

$$p_a = \frac{\Gamma(\nu)}{\nu^\nu e^{1-\nu}} \approx \sqrt{\frac{e^2 2\pi}{\sqrt{\nu-1}}}$$

ultima relație rezultând din aproximarea lui Stirling pentru $\nu \rightarrow \infty$:

$$\Gamma(\nu) \approx (\nu-1)^{\nu-1} e^{-(\nu-1)} \sqrt{2\pi(\nu-1)}$$

2.2 Al doilea algoritm de respingere pentru variabila

$X \sim \text{Gama}(0, 1, \nu)$ cu $\nu > 1$.

Algoritmul de mai sus este lent pentru ν foarte mare, de aceea vom prezenta un alt algoritm de respingere, de data aceasta bazat pe o înfășurătoare dată de o densitate Cauchy nestandard trunchiată pe $[0, \infty)$:

$$h(x) = \frac{k}{1 + \frac{(x - (\nu - 1))^2}{c}}, \quad x \geq 0 \quad (8)$$

unde k este o constantă de normare. Atunci are loc următoarea teoremă:

Teoremă

Dacă se înfășoară densitatea Gama(0, 1, ν), $\nu > 1$ cu densitatea $h(x)$ dată de (8), atunci pentru $c \geq 2\nu - 1$ avem:

$$r(x) = \frac{f(x)}{h(x)} \leq \alpha = \frac{1}{k\Gamma(\nu)}(\nu - 1)^{\nu-1}e^{-(\nu-1)}. \quad (9)$$

Dem:

Avem

$$r(x) = \frac{1}{k\Gamma(\nu)}\varphi(x)$$

unde

$$\varphi(x) = x^{\nu-1}e^{-x} \left[1 + \frac{(x - (\nu - 1))^2}{c} \right].$$

Atunci:

$$\varphi'(x) = -\frac{e^{-x}x^{\nu-1}}{c}[x - (\nu - 1)][(x - \nu)^2 + c - (2\nu - 1)]$$

de unde rezultă că ecuația $\varphi'(x) = 0$ are soluția $x_0 = \nu - 1 > 0$ iar dacă $c \geq 2\nu - 1$ atunci x_0 este punct de maxim. Dacă luăm $c = 2\nu - 1$ atunci avem:

$$\alpha = \frac{1}{k\Gamma(\nu)}(\nu - 1)^{\nu-1}e^{-(\nu-1)}.$$

Din această teoremă rezultă următorul algoritm de generare a unei variabile $Gama(0, 1, \nu)$ cu $\nu > 1$:

Algoritm Gama3

Intrare: ν , $b = \nu - 1$, $c = \nu + b$, $s = \sqrt{2\nu - 1}$

P1: Se generează $U \sim U(0, 1)$, $T := s \cdot tg[\pi(U - 0.5)]$ (T este o variabilă Cauchy standard generată cu metoda inversă);

P2: $Y = b + T$ (Y este o variabilă Cauchy nestandard);

P3: Dacă $Y > 0$ mergi la P4, altfel mergi la P1;

P4: Se generează $U_1 \sim U(0, 1)$;

P5: Dacă $U_1 \leq e^{b \log(Y/b) - T + \log(1 + T^2/c)}$ mergi la P6, altfel mergi la P1;

P6: $X = Y$.

Ieșire: Variabila aleatoare X .

Constanta de normare k nu intervine în construcția algoritmului, dar ea este necesară pentru a calcula probabilitatea de acceptare p_a . Se verifică ușor că:

$$k = \left[\frac{\pi}{2} + \operatorname{arctg} \left(-\frac{\nu - 1}{\sqrt{2\nu - 1}} \right) \right]^{-1}.$$

Un **alt algoritm de generare** pentru o variabilă $Gama(0, 1, \nu)$ cu $\nu > 1$ se poate obține folosind următorul raționament: fie

$$\nu = k + p$$

unde $k = \lfloor \nu \rfloor$ este partea întreagă și $p = \nu - k \in [0, 1)$. Atunci

$$X = E_k + Y$$

unde E_k este variabila Erlang de parametru k , Y este o variabilă $Gama(0, 1, \nu)$ cu $\nu < 1$, iar E_k și Y sunt independente.

Deci X se poate genera ca sumă de o variabilă Erlang și o variabilă Gama cu ν subunitar.